

דו"ח:

לורן מנצור ת"ז: 208711218

נעמה קולמבוס ת"ז: 213119324

תיאור הדאטה המעובד וטבלת הפיצ'רים:

נוסחא	איפה העמודה נוצרה	משמעות	מוטיבציה
avg_actor_experience	פייפליין	שנות הניסיון הממוצע של השחקנים ברשימה	האמנו שיש קשר חיובי בין ניסיון הכוכבים לבין ההשפעה בדירוג
max_actor_experience	פייפליין	הניסיון הכי גבוה	
sum_actor_experience	פייפליין	סכום שנות הניסיון של כל השחקנים בסרט	
startYear	מהדאטה המקורי	שנת יציאת הסרט	
runtimeMinutes	מהדאטה המקורי	משך זמן הסרט	
plot_word_count	מהפונקציה prepare_data	כמות המילים בתקציר	אולי אורך התקציר משפיע
decade	מהפונקציה prepare_data	באיזה עשור יצא הסרט	אולי יש תקופות עם סרטים טובים יותר
duration_category	מהפונקציה prepare_data	משך זמן הסרט כחלוקה ל3 קבוצות (0-קצרת 1- בינוני נורמלי, 2-ארוך)	היה לנו הגיוני שסרטים קצרים מדי לא תמיד מצליחים לסחוף את הצופה, וסרטים ארוכים מדי יכולים לעייף ולשעמם. ובכך להוריד דירוג.
num_lead_actors	מהפונקציה prepare_data	כמות הכוכבים בסרט	האמנו שיש קשר חיובי בין כמות הכוכבים המשתתפים בסרט לבין ההשפעה בדירוג
is_english	מהפונקציה prepare_data	האם הסרט באנגלית או לא	אנגלית היא שפה בינלאומית, אולי יש לזה השפעה כלשהי בדירוג.
is_drama	מהפונקציה prepare_data	האם זה סרט דרמה או לא	סרטי דרמה בדרך כלל סוחפים את הצופים.
is_us	מהפונקציה prepare_data	האם הוא סרט אמריקאי או לא	סרטים אמריקאיים בד"כ מוכרים יותר לקהל הרחב.

הסבר על שלושת העמודות שנוצרות בפייפליין:

במסגרת הנדסת הפיצ'רים, יצרנו מחלקה בשם **ActorExperienceTransformer** זוהי מחלקה מסוג Custom Transformer המשתלבת בתוך ה Pipeline של המודל.

המילון במחלקה שומר את מספר הסרטים שבהם הופיע כל שחקן, לפי ה ID שלו. בשלב האימון, המחלקה עוברת על רשימת השחקנים בסרטים, סופרת את ההופעות של כל שחקן ומאחסנת את הנתונים במילון. חשוב לציין שהחישוב מתבצע אך ורק על סמך נתוני האימון בלבד, כדי שהמודל לא יחשוף מידע מראש על הנתונים שהוא אמור לחזות.

העמודות שהמחלקה מייצרת הן:

avg_actor_experience: הניסיון הממוצע של כל השחקנים המשתתפים בסרט.

max_actor_experience : הניסיון של השחקן בעל מספר ההופעות הגבוה ביותר מתוך הקאסט של הסרט.

sum_actor_experience: סך כל הופעות העבר של כל השחקנים בסרט במצטבר.
כל החישובים הללו מבוצעים בתוך ה Pipeline כדי להבטיח שכל עמודה תתבסס רק על הנתונים המותרים, ובכך נמנעת זליגת מידע.

איך נראה הדאטה המעובד בעקבות הפייפליין:

במסגרת Pipeline חילקנו את העבודה ל-3 קבוצות עיבוד נפרדות.

1. העמודות המספריות: `['startYear', 'runtimeMinutes', 'plot_word_count', 'num_lead_actors', 'decade', 'duration_category']`
לערכים חסרים הוספנו חציון ולא ממוצע בשביל לא להיות מושפעים מערכים קיצוניים ונרמלנו לפי `StandardScaler()`

2. העמודות הבינאריות: `['is_english', 'is_drama', 'is_us']`
לערכים החסרים הוספנו את הערך השכיח ולא נרמלנו משום שהם כבר בינאריות

3. בעמודה זו ['lead_actors_ids']
טיפלנו על ידי שליחה למחלקה שיצרנו `ActorExperienceTransformer()`
ונוצרו 3 עמודות: (ממוצע ניסיון, מקסימום ניסיון, סכום ניסיון)
לערכים חסרים הוספנו חציון ולא ממוצע בשביל לא להיות מושפעים מערכים קיצוניים ונרמלנו לפי `StandardScaler()`

prepare data:

בפונקציה זו קיבלנו את הדאטה הגולמי וביצענו את הפעולות הבאות:

1. פונקציית count_actors
זוהי פונקציית עזר המקבלת את עמודת השחקנים (`lead_actors_ids`).
היא בודקת אם הערך הוא ריק, מחרוזת ריקה או NaN ובמקרה כזה מחזירה 0. אחרת,
היא משתמשת ב `ast.literal_eval` כדי להפוך את המחרוזת שמייצגת רשימה (של מזהה השחקנים) לרשימה אמיתית בפיתון, ואז מחזירה את מספר האיברים ברשימה (אורך הרשימה).

2. יצירת עמודות חדשות:

- ❖ **Num lead actors**: הפעלת הפונקציה `count_actors` על עמודת השחקנים.
- ❖ **duration category**: שימוש ב `np.select` כדי לחלק את `runtimeMinutes` ל-3 קטגוריות מספריות: 0 (מתחת ל-90 דקות), 1 (בין 90 ל-130 דקות), ו-2 (מעל 130 דקות). ערכים שלא עומדים בתנאים מקבלים NaN
- ❖ **Plot word count**: שימוש ב `apply` כדי לפצל את טקסט העלילה למילים בודדות ולספור את כמותן, תוך טיפול בערכים חסרים.

❖ **is english**: בדיקת עמודת השפה, ניקוי רווחים והפיכת הטקסט ל Title Case
אם הערך הוא "English", מוצב 1, אחרת 0 (אם הערך חסר), אם נתון ערך NaN
הוא נשאר כך.

❖ **is drama**: חיפוש המחוזות "Drama" בתוך עמודת הז'אנרים. אם נמצא=1,
אחרת 0 (ערכים חסרים מטופלים בהתאם).

❖ **is us**: בדיקה האם עמודת המדינה (Country) מכילה את אחת מהמחוזות :
'United States', 'United States of America', 'USA', 'US'. אם כן מוצב 1,
אחרת 0.

❖ **decade**: חישוב העשור על ידי חילוק שלם (//) של שנת היציאה ב-10 והכפלה
ב-10.

3. ניקוי עמודות :

הסרת העמודות המקוריות ששימשו ליצירת הפיצ'רים החדשים, numVotes,
BoxOffice, tconst, primaryTitle, plot, Country, Language, genres, budget
averageRating ובנוסף עמודות שגורמות לזליגת מידע.

3.2 נימוק לבחירת המודל (Random Forest)

בחרנו ב Random Forest כמודל השני בגלל עמידתו הרבה יותר מעץ החלטה בודד. העץ הבודד
נוטה ל-התאמת יתר (Overfitting) ולרגישות גבוהה לרעש ולערכים חסרים בדאטה. לעומת זאת,
Random Forest משקלל מאות עצים ומפחית את ההשפעה של טעויות מקומיות.
היתרון הזה בא לידי ביטוי בתוצאות ה Cross-Validation שבהן ה Random Forest הציג ביצועים
עדיפים משמעותית על פני עץ ההחלטה בודד.

השוואת שני המודלים, עם מדדי ביצועים מ-10 fold CV

לפי הקוד: המדדים של Elastic Net:

	Mean	Std_Dev
RMSE	1.239138	0.008291
MAE	0.965785	0.007145
R2	0.081149	0.004031

לפי הקוד: המדדים של Random forest:

	Mean	Std_Dev
RMSE	1.189700	0.008519
MAE	0.911545	0.007182
R2	0.153003	0.005278


ניתן לראות שבכל המדדים מודל

Random forest קיבל תוצאות טובות יותר

ניתוח חשיבות הפיצ'רים:

```
is_drama      0.312231
num_lead_actors -0.266900
runtimeMinutes 0.205732
is_english    -0.143912
max_actor_experience -0.128403
dtype: float64
```

מודל Elastic Net - חמשת הפיצ'רים שהכי עזרו לו לנבא:



is drama - השפעה חיובית, סרטים שמוגדרים כדרמה נוטים לקבל ציון גבוה יותר.

Run time minutes - השפעה חיובית, סרטים ארוכים יותר נוטים לקבל ציון גבוה יותר.

Num lead actors - השפעה שלילית, ככל שיש יותר "כוכבים" הציון החזוי נוטה לרדת.


Is English - השפעה שלילית, סרטים בשפה האנגלית נוטים לקבל ציון נמוך יותר לפי המודל הזה.

Max actor experience - השפעה שלילית, ככל שלשחקן הראשי יש יותר ניסיון, הציון החזוי

נוטה לרדת.

```
runtimeMinutes 0.253653
num_lead_actors 0.188194
startYear      0.163689
is_drama       0.162752
plot_word_count 0.074202
dtype: float64
```

Top 5 Features Importance - Random Forest




מודל Random forest

לפי הגרף אפשר לראות מי ה-5 הפיצ'רים שהכי עזרו לנבא,

אך לא ניתן להבין האם הכיוון הוא חיובי

או שלילי ולכן הוצאנו לכל אחת

מה-5 עמודות גרף שיראה את הכיוון:



לפי הגרף:

Run time minutes – קשר חיובי, ככל שזמן הסרט ארוך יותר, המודל צופה לו ציון גבוה יותר.

Num lead actors - קשר משולב, המודל צופה את הציון הגבוה ביותר לסרטים עם שחקן ראשי אחד, אך ככל שמספר השחקנים עולה מעבר לכך, הקשר הופך לשלילי והציון החזוי יורד ומתייצב.

Start Year קיים קשר שלילי, ככל שהסרט חדש יותר, המודל צופה לו ציון נמוך יותר בהשוואה לסרטים ישנים.

Is drama קיים קשר חיובי, המודל צופה ציונים גבוהים יותר לסרטים שמוגדרים כדרמה בהשוואה לאלו שלא.

Word count אין קשר מובהק (קשר ניטרלי), המודל מציג קו שטוח שכמעט אינו משפיע על הציון החזוי

	ElasticNet_Importance	RandomForest_Importance
is_drama	0.312231	0.162752
is_english	-0.143912	NaN
max_actor_experience	-0.128403	NaN
num_lead_actors	-0.266900	0.188194
plot_word_count	NaN	0.074202
runtimeMinutes	0.205732	0.253653
startYear	NaN	0.163689

האם המודלים מסכימים?

ואיפה הם מתפצלים?

קיימת הסכמה בין שני המודלים לגבי חשיבותם של:

run time Minutes, is drama, num lead actors, אשר הופיעו בין חמשת הפיצ'רים החשובים ביותר בשני המודלים.

לעומת זאת, קיים פיצול בשאר הפיצ'רים:

מודל Elastic Net זיהה את is english, max actor experience כחשובים, בעוד שמודל Random Forest זיהה את plot_word_count, startYear כחשובים. הבדלים אלו נובעים מאופי המודלים.

Elastic Net הוא מודל ליניארי שמזהה בעיקר קשרים ליניאריים וישירים עם המשתנה המנובא.

Random Forest מבוסס על עצי החלטה ומסוגל ללכוד גם קשרים לא ליניאריים וגם אינטראקציות בין משתנים.

לכן, כל מודל עשוי להדגיש פיצ'רים שונים בהתאם לאופן שבו הוא לומד את הנתונים.

סעיף 5 - ניתוח שגיאות:

5.2 - 5 סרטים:

סרטים עם Overprediction גדול

Vixen Highway 2006 It Came from Uranus!

סרט אקשן ואימה משנת 2010 בעל דירוג נמוך מאוד (1.2). המודל העריך את הסרט גבוה מהדירוג בפועל, כנראה משום שהמאפיינים שלו לא שיקפו את איכותו הנמוכה במיוחד. המודל לא יודע את הפלוט ואת השפה המקוריים

Trilogy of Bloody Guts גם סרט אימה, משנת 2015 עם דירוג דומה, 1.2 בלבד. ייתכן שהמודל התקשה לזהות שמדובר בסרט עם תחום מסוים או בעל קבלה שלילית מאוד בקרב הצופים, ולכן חזה דירוג גבוה יותר. המודל לא יודע את רשימת השחקנים.

Justin Bieber Always Believing סרט תיעודי מוזיקלי משנת 2012 בעל דירוג 1.0. המודל ביצע Overprediction משמעותי, ככל הנראה משום שהמאפיינים הקיימים בנתונים אינם משקפים את תגובת הקהל או את הביקורות שקיבל הסרט בפועל. המודל לא יודע את השפה.

סרטים עם Underprediction גדול

Il Santo Veleno סרט מתח משנת 2023 בעל דירוג גבוה במיוחד 9.4. המודל העריך את הסרט בדירוג נמוך משמעותית מהדירוג בפועל. ייתכן שהמודל התקשה לזהות מאפיינים ייחודיים שהפכו את הסרט למוערך אצל הצופים. המודל לא יודע את השפה ואת המדינה

Charlie, Trevor and a Girl Savannah סרט פשע, רומנטיקה ומתח משנת 2015 עם דירוג 8.5. המודל ביצע Underprediction כנראה משום שהמאפיינים הזמינים אינם משקפים במלואם את איכות העלילה או את חוויית הצפייה שהובילה לדירוג הגבוה.

הרבה outliers- מהסרטים היותר חדשים מהעשורים האחרונים גם ב **Overprediction** וגם ב **Underprediction** וגם מתוך כל העשרים להרבה יש חוסר בעמודת plot ו שפת הסרט

5.3

Number of overlapping outliers: 3			
	tconst	primaryTitle	st
61912	tt22098258	Twenty One Pilots: Cinema Experience Extended Cut	
2194	tt13110798	Il nostro paradiso	
67980	tt1666348	Vixen Highway 2006: It Came from Uranus!	

יש 3 סרטים חופפים

Random Forest טועה בעיקר ב-

סרטים עם דירוג קיצוני (גבוהים או נמוכים), וסרטים עם מאפיינים חריגים או מידע חסר, שבהם קשה לו לקלוט דפוסים לא סטנדרטיים.

Elastic Net טועה בעיקר במקרים שבהם הקשר בין הפיצ'רים לרייטינג אינו ליניארי (כבר ציינו שזה מודל לינארי) או כאשר יש אינטראקציות מורכבות בין משתנים שהוא לא מצליח ללכוד.

כאשר מודל אחד טועה, האם השני מצליח יותר?

כאשר random forest טועה :

Random Forest של RMSE: 5.048
Elastic Net של RMSE: 4.432

על המקרים שהוא עצמו טעה בהם: Elastic Net 5.205 של RMSE
על אותם מקרים בדיוק: Random Forest 4.370 של RMSE

כשאר elastic net טועה:

5.4 פיצ'רים שאין אצלנו ואולי היו עוזרים לשפר תוצאות:

1. להציג את הבימאים
2. להתייחס לכל הז'אנרים ולא רק לז'אנר המוביל.
3. להתייחס לא רק לארצות הברית אלא לפחות לטופ 5.

6_ חתכנו בקוד לפי ארצות הברית או לא ולפי עשורים(1900,1990,2010,2020)

6.3

Total Model RMSE: 1.1897

Category	RMSE	Deviation_Percent
0 US	1.0137	-14.795609
1 Non-US	1.2218	2.695793
2 1900	1.7264	45.108869
3 1990	1.1169	-6.121353
4 2010	1.2866	8.142418
5 2020	1.3632	14.580868

הטבלה מראה כמה המודל "טועה" בחיזוי דירוגים של סרטים
מקטגוריות שונות, בהשוואה לשגיאה הממוצעת שלו
על כל הסרטים (1.1897).

סימן מינוס (-): המודל מדויק יותר מהממוצע, הוא טועה פחות.
סימן פלוס (+): המודל פחות מדויק מהממוצע, הוא טועה יותר.

מה קרה בפועל:

בארה"ב, המודל פגע הכי טוב – הוא מדויק ב-14.8% יותר מהממוצע.
בשנות ה-90, המודל מדויק ב-6.1% יותר מהממוצע.
בסרטים שאינם מארה"ב, המודל פחות מדויק מהממוצע ב-2.7%.
בשנות ה-2010, המודל פחות מדויק מהממוצע ב-8.1%.
בשנות ה-2020, המודל פחות מדויק מהממוצע ב-14.6%.
בשנות ה-1900, המודל הכי פחות מדויק – הוא טועה ב-45.1% יותר מהממוצע.

בעשור 1900 המודל היה הכי פחות מדויק!

מצאנו בקוד שזה נובע ממחסור גדול בדאטה של העשור הזה

בגלל שזה פער מאוד גדול מהממוצע, זה אכן מעלה חששות שהמודל לא ידע להתמודד בכלל עם
סרט שבא מעשור זה.
חוסר בנתונים הוא מנבא מובהק להטיה. כאשר החוסר של הנתונים אינו אקראי אלא שיטתי, כפי
שקורה בדאטה שלנו בעשור 1900 – הוא יוצר "תת ייצוג" של קבוצה מסוימת. כתוצאה מכך,
המודל אינו לומד את מאפייני הקבוצה החסרה ומפתח הטיה (Bias) לטובת הקבוצות שכן מיוצגות,
מה שהופך את התחזיות שלו ללא מהימנות עבור אותם מקרים חסרים.

מניעת Data Leakage

כל קובץ הנתונים שקיבלנו שימש כקובץ אימון, והמודל נבחר בסופו של דבר על סמך ביצועי ה-
10 Fold Cross Validation.

Prepare data - פונקציה העיבוד מופעלת על קובץ הנתונים המלא עוד לפני ה Cross Validation.
כל שבעת המשתנים שפיתחנו בתוך הפונקציה מבוססים על חישובים ברמת השורה הבודדת.
הפונקציה לא משתמשת באף מדד סטטיסטי קבוצתי (היא לא מחשבת ממוצעים של עמודות,
חציונים או מילוי ערכים חסרים המושפעים משורות אחרות). לכן, אין השפעה הדדית בין הסרטים.

Actor Experience Transformer - האתגר המורכב ביותר בקוד היה הטיפול במזהי השחקנים כדי לחשב את מדדי הניסיון שלהם. אם היינו סופרות מראש כמה סרטים כל שחקן עשה על גבי כל הקובץ, המודל היה מקבל מידע על "העתיד" (הוא היה יודע על סמך כל הקובץ כמה סרטים השחקן עשה בסך הכל). כדי למנוע את זה, הכנסנו את מנגנון הספירה כשלב מובנה בתוך ה Pipeline של המודל. בניית מילון הניסיון של השחקנים מתבצעת אך ורק בזמן פקודת ה fit של ה Pipeline על נתוני האימון הפנימיים של אותו Fold ספציפי. חלק "נשאר בצד" ומקבל רק חישוב פסיבי, מבלי להשפיע על הידע של המודל.

שינוי קנה המידה (Scaling) - אם היינו מנרמלות את כל הנתונים מראש, הממוצע וסטיית התקן הכלליים היו מושפעים גם מחלקי הוולידציה, ומחלחלים בצורה לא חוקית לשלב הלמידה. כדי למנוע זאת, שילבנו את ה Pipeline בתוך תהליך ה Cross Validation. בכל אחד מ-10 פולד של הקרוס ולידציה, ספריית Scikit-Learn מבודדת לחלוטין את החישובים. ה StandardScaler מריץ את פקודת ה fit ומחשב את הממוצע וסטיית התקן על פולדי האימון. פולד הוולידציה הנסתר מנורמל באופן פאסיבי (transform) על בסיס הערכים הללו בלבד, ללא שום יכולת להשפיע עליהם.

תחזיות Predictions – אם היינו מפיקות תחזיות על ידי הפעלת פקודת predict רגילה על הדאטה אחרי שהמודל כבר התאמן עליו, המודל היה נותן ניחושים אופטימיים מדי על סרטים שהוא כבר מכיר בעל פה. לכן השתמשנו בפונקציה: `cross_val_predict`. המודל מנחש אך ורק את פולד הוולידציה המבודד של אותה הנתונים שהוא לא התאמן עליהם. כתוצאה מכך, התחזית עבור כל סרט נוצרה כאשר הסרט הזה שימש כ"נתון עתידי" אבל נסתר מהמודל. הדבר מבטיח שניתוח השגיאות הקיצוניות וניתוח ההוגנות מבוססים על ערכים ריאליים ומשקפים את כושר ההכללה האמיתי של המודל, בדיוק כפי שהוא יתנהג על קובץ הטסט החיצוני שנקבל.

סיכום: מסקנות, מגבלות והצעות להמשך.

מגבלות

בעמודת התקציב ראינו שהיה המון ערכים חסרים ולכן החלטנו להוריד אותה

הצעות להמשך

- **הוספת פיצ'רים איכותיים** - כדי לפתור את "הנוסחאות היבשות" של המודל, היה מומלץ להעשיר את הדאטה במשתנים המשקפים את המוניטין ההיסטורי של יוצרי הסרט. למשל, ניתן לחשב את ממוצע הציונים הקודמים של הבמאי או להוסיף את תקציב הסרט (תקציב גבוה יכול להעיד על יכולות הפקה ועניין ציבורי).

הרחבת הייצוג הגיאוגרפי והז'אנרי: כפי שצינו קודם, כרגע המודל מתייחס רק לז'אנר דרמה ולמדינה המובילה ארה"ב. כדי לשפר את הדיוק עבור סרטים בינלאומיים, מומלץ להרחיב את הפיצ'רים הבינאריים ולכלול התייחסות לפחות לחמש המדינות המובילות בדאטה וכן לז'אנרים מרכזיים נוספים (כמו קומדיה ואקשן).

- **איזון נתונים לעשורים חסרים** - כדי לפתור את השגיאה של העשורים הישנים (כמו 1900), מומלץ להשתמש בטכניקות של דגימת חסר או הוספת נתונים היסטוריים חיצוניים, כדי לאפשר למודל ללמוד את המאפיינים של סרטים אלו בצורה הוגנת ויציבה יותר.

נספחים:

AI usage log

במסגרת העבודה על הפרויקט, בעיקר בקוד ובכתיבת הדו"ח המסכם, נעזרנו בג'מיני .

על מה התייעצנו?

❖ **הבנה מתודולוגית של זליגה (Data Leakage):** התייעצנו עם המודל לגבי הדרכים השונות שבהן Pipeline מונע זליגה בתוך ה- Cross Validation וחידדנו את הלוגיקה מדוע יצירת הפיצ'רים בתוך הפונקציה `prepare_data` חסינה מזליגה (פעולות ברמת השורה הבודדת בלבד).

❖ **עריכה וליטוש שפתי:** נעזרנו ב AI לצורך שיפור רמת הניסוח והפיכת פסקאות הדו"ח לרשמיות ואקדמיות יותר.

איך וידאנו שהתוצאות נכונות?

❖ **חשיבה ביקורתית והצלבת מקורות -** כל הסבר תיאורטי שסופק על ידי המודל הוצלב ונבחן מול המצגות והקודים של חן ושאין טעות של ג'מיני.